

개인화 연합학습 기반 전기차 배터리 SOH 예측 및 프라이버시 보존형 이상 징후 경고

김유*, 박준영*, 신민철*, 황솔*, 박정원*, 서왕덕**

Personalized Federated Learning-Based EV Battery SOH Prediction and Privacy-Preserving Battery Fault Warning

Yu Kim*, Junyoung Park*, Mincheol Shin*, Sol Hwang*, Jungwon Park*, Wangduk Seo**

요 약

전기차(Electric Vehicle, EV) 배터리의 건전성 상태(State of Health, SOH) 예측과 이상 징후의 조기 감지는 차량의 안전성 확보와 유지관리 효율성에 직결되는 핵심 기술이다. 실제 전기차 배터리 상태 추정에서는 차량 단말에서 수집된 운용 데이터를 서버 또는 클라우드에서 통합 학습하는 방식이 널리 사용되어 왔다. 그러나 이러한 중앙집중식 학습 방식은 차량에서 수집되는 전압, 전류, 온도 등 민감한 주행 및 충전 데이터를 중앙 서버로 전송하는 과정에서 사용자 프라이버시 침해 가능성과 통신 비용 및 네트워크 부담을 야기할 수 있다. 또한 실제 EV 배터리 데이터는 차량별 운행 습관, 충전 패턴, 운용 환경이 서로 다른 비독립 비동일분포(Non-IID) 특성을 가지므로, 표준 연합학습만으로는 개별 차량 특성을 충분히 반영하기 어렵다. 본 논문은 이러한 한계를 해결하기 위해 개인화 연합학습(pFL) 기반 전기차 배터리 SOH 예측 아키텍처와 보조적인 임계값 기반 이상징후 경고 기능을 결합한 하이브리드 구조를 제안한다.

Abstract

State of Health (SOH) prediction and early anomaly detection for Electric Vehicle (EV) batteries are critical to vehicle safety and maintenance efficiency. In practical EV battery health prediction, operational data collected at vehicle-side devices are often aggregated and learned within server- or cloud-based centralized frameworks. However, such centralized learning approaches generally require sensitive driving and charging data, including voltage, current, and temperature, to be transmitted to a central server, thereby raising privacy concerns as well as communication and network overhead. Furthermore, since real-world EV battery data exhibits non-independent and non-identically distributed (Non-IID) characteristics due to varying driving habits, charging patterns, and operating environments across vehicles, standard federated learning is insufficient to adequately reflect individual vehicle traits. To address these limitations, this paper proposes a hybrid architecture that combines a Personalized Federated Learning (pFL)-based EV battery SOH prediction framework with an auxiliary threshold-based anomaly warning function.

Key words

State of Health (SOH), EV battery, Personalized Federated Learning (pFL)

* 경기대학교 소프트웨어경영대학 AI컴퓨터공학부, {kimyou3000@naver.com, young1221@kyonggi.ac.kr, zero777960@kyonggi.ac.kr, wood0119@kyonggi.ac.kr, piw5454@kyonggi.ac.kr, wdseo@kyonggi.ac.kr} (교신저자)

※ 본 연구는 과학기술정보통신부 및 정보통신기획평가원의 SW중심대학원지원사업의 연구결과로 수행되었음 (2021-0-01393)

I. 서론

전 세계적인 전동화 확산과 탄소중립 정책의 강화에 따라 전기차(EV) 배터리의 상태를 정확하게 진단하고 관리하는 기술의 중요성이 지속적으로 증가하고 있다. 특히 배터리의 건전성 상태(State of Health, SOH)는 잔존 성능, 유지보수 시점, 중고차 가치 평가, 폐배터리 재사용 여부 판단 등과 밀접하게 연결되는 핵심 지표이며, 배터리 이상 징후를 조기에 감지하는 기능 역시 차량의 안전한 운용과 유지관리 효율성 확보를 위해 중요하다. 이러한 배경에서 배터리 상태 예측과 이상 징후 감지를 정밀하고 실용적으로 수행하기 위한 데이터 기반 접근이 활발히 연구되고 있다. 최근 배터리 상태 예측 분야에서는 딥러닝을 포함한 데이터 기반 방법이 널리 활용되고 있으며, 실제 전기차 배터리 상태 예측 연구에서도 차량 단말에서 수집된 운용 데이터를 서버 또는 클라우드에서 통합 학습하는 방식이 주로 사용되어왔다 [1]. 이러한 중앙집중식 학습 방식은 전압, 전류, 온도와 같은 운용 데이터를 통합적으로 활용하여 높은 예측 성능을 기대할 수 있다는 장점을 가진다. 그러나 차량에서 생성되는 민감한 주행 및 충전 데이터를 외부 인프라로 전송해야 하므로 프라이버시 및 보안 측면의 우려가 존재하며, 대규모 차량군에 적용할 경우 통신 비용과 시스템 확장성 측면에서도 부담이 발생한다. 또한 실제 도로 주행 기반 데이터는 차량별 운행 습관, 충전 패턴, 운용 환경, 온도 조건, 열화 양상 등의 차이로 인해 강한 비독립동일분포(Non-IID) 특성을 보이므로, 모든 차량에 동일한 전역 모델을 적용하는 표준 연합학습만으로는 개별 차량의 특성을 충분히 반영하기 어렵다. 이러한 한계를 보완하기 위해 최근 배터리 분야에서도 프라이버시 보존형 협력 학습 구조가 주목받고 있다. Santos 등은 실제로 도로 주행 기반 20대 EV 데이터를 활용하여 연합 학습 기반 SOH 예측(prognosis) 프레임워크를 제안하였으며, 차량 간 데이터가 높은 Non-IID 특성을 가짐에도 불구하고 연합학습이 유효하게 작동할 수 있음을 보였다 [2]. Yang 등은 30개 충전소와 10,154대 EV의 실제 충전 데이터를 바탕으로 개인

화 연합학습 기반 배터리 이상 경고 프레임워크를 제안하여, 데이터 소유자별 이질성과 fault sample 불균형이 존재하는 환경에서도 프라이버시를 보존하는 협력 학습의 가능성을 보여주었다 [3]. 또한 Wang 등은 SOH 예측을 위해 적응형 다중 개인화 연합학습 기법을 제안하고, personalization과 differential privacy를 결합하여 기존 FL 및 로컬 학습 대비 정확도 향상을 보고하였다 [1]. 그러나 기존 연구들은 SOH prognosis, 이상 경고, 또는 적응형 개인화 SOH 예측을 각각 개별적으로 다루고 있으며, 실제 차량별 이질성을 반영한 SOH 예측과 엡지 단에서 즉시 동작하는 경량 이상 징후 경고 기능을 하나의 실용적 프레임워크 안에서 함께 다루는 접근은 여전히 제한적이다. 이에 본 연구에서는 개인화 연합학습(Personalized Federated Learning, pFL)을 기반으로 한 전기차 배터리 SOH 예측 아키텍처와 프라이버시 보존형 이상 징후 경고 기능을 결합한 하이브리드 프레임워크를 제안한다. 제안 방법은 차량 간 공유 가능한 표현은 전역적으로 학습하되, 차량별 데이터 특성은 로컬 적응을 통해 반영하도록 설계하여 Non-IID 환경에서의 SOH 예측 성능 향상을 목표로 한다. 또한 SOH 예측 모듈과 별도로, 엡지 단말에서 독립적으로 동작하는 임계값 기반 이상 징후 경고 모듈을 구성하여, 프라이버시를 보존하면서도 보다 실용적인 현장 대응 가능성을 확보하고자 한다. 본 논문의 주요 기여는 다음과 같다. 첫째, 실제 도로 주행 기반 배터리 데이터 환경에서 차량별 이질성을 고려한 개인화 연합학습 기반 SOH 예측 구조를 제안한다. 둘째, 원시 데이터의 중앙 집중 수집 없이도 차량 단말에서 학습과 추론을 수행하는 프라이버시 보존형 분산 학습 아키텍처를 설계한다. 셋째, 개인화 연합 학습 기반 SOH 예측 모듈과 엡지 단의 임계값 기반 이상 징후 경고 모듈을 결합하여, 예측 정확도와 실용적 대응성을 함께 고려한 하이브리드 프레임워크를 제시한다.

II. 제안 시스템 및 문제 정의

본 장에서는 본 논문에서 제안하는 개인화 연합 학습 기반의 SOH 예측 및 이상 징후 경고 시스템

템의 전체 아키텍처와 구체적인 문제 정의를 기술한다. 제안 시스템은 K개의 차량 엡지 노드로 구성되며, 각 노드는 장기적 노화 추론을 위한 (pFL 기반 SOH 예측(Module 1)과 즉각적 안전 대응을 위한 엡지 기반 이상 감지(Module 2)를 독립적으로 수행하는 하이브리드 프레임워크이다.

II - i. 시스템 모델 및 실시간성 정의

각 차량 엡지 노드 k는 주기적 태스크 $T_{soh}(soh)$ 와 T_{safe} (이상 감지)를 수행한다. 시스템의 실시간 안전성 확보를 위해 Module 2의 이상 감지 태스크는 다음과 같은 하드 리얼타임 데드라인(D_{safe})을 만족해야 한다.

$$R(e)_{safe} \leq D_{safe} \ll P_{soh} \quad (1)$$

$R(e)_{safe}$ 는 이이상 사건 발생 시점부터 경고 신호(SOS) 송출까지의 실제 응답 시간을 의미한다. P_{soh} 은 SOH 예측 모델이 갱신되는 단위인 충전 사이클 주기로, 이상 감지 태스크는 이보다 훨씬 짧은 주기로 실행되어 즉각적인 대응성을 확보한다. 제안 시스템은 엡지 컴퓨팅을 활용하여 네트워크 지연 시간을 배제함으로써 $R(e)_{safe}$ 를 최소화한다.

II - ii. pFL 기반 SOH 예측 (Module 1)

본 연구에서는 차량별 주행 이질성(Non-IID) 문제를 해결하기 위해, 모델 파라미터 θ 를 전역적 특징 추출기인 표현부(v)와 차량별 개인화 헤드(h)로 구조적으로 분리하는 FedRep 계열의 개인화 연합학습 방식을 채택한다. 각 차량 엡지는 수집된 원시 데이터로부터 학습에 필요한 SOH 라벨을 직접 생성한다. 이때 선행 논문에서 제안된 방식을 따라, 충전 사이클 동안의 전류적분법(Coulomb Counting)을 통해 배터리 용량을 추정하고, 측정 노이즈를 제거하기 위해 롤링 메디안(Rolling Median) 필터를 적용하여 평활화된 SOH 값을 타겟으로 사용한다 [2].

k번째 차량의 데이터셋에 대한 예측값 $\hat{y}$ 는 다음과 같이 정의 된다.

$$\hat{y} = f_{h_k}(f_v(X; v); h_k) \quad (2)$$

여기서 입력 X는 최근 5개 충전 사이클의 시계열 데이터를 포함하는 텐서이며, 출력 $\hat{y}$ 는 현재 및 향후 2개 사이클의 SOH를 포함하는 예측 벡터이다. v 는 모든 클라이언트가 공유하는 전역 표현부이며, h_k 는 k번째 차량의 개인화 헤드이다. 전체 시스템의 최적화 목적 함수는 각 클라이언트의 손실 함수의 가중합을 최소화하는 것이며, 이는 다음과 같이 공식화된다.

$$\min_{V, h_1, \dots, h_K} \sum_{k=1}^K \frac{n_k}{N} l_k(v, h_k) \quad (3)$$

여기서 n_k 는 k번째 차량이 로컬 데이터 샘플 수를 의미하고, N 은 전체 샘플 총합, l_k 는 실제 SOH 라벨과 모델의 예측값 사이의 오차를 계산하는 로컬 손실 함수를 나타낸다.

각 차량 엡지 노드는 서버로부터 수신한 전역 표현부 v 를 기반으로 매 라운드마다 2단계 교대 최적화를 수행하여 모델을 갱신한다. 먼저 서버로부터 수신한 전역 표현부 $v^{(t)}$ 를 동결한 상태에서, 차량 k가 보유한 로컬 데이터를 사용하여 개인화 헤드 h_k 를 최적화한다. 이 과정은 차량별 고유한 주행 패턴 및 배터리 특성(Non-IID)을 헤드 계층에서 우선적으로 흡수하게 함으로써 모델의 개인화 성능을 극대화한다. 이후 최적화가 완료된 헤드 $h_k^{(t+1)}$ 를 고정된 상태에서, 전역 표현부 v_k 를 업데이트한다. 이를 통해 차량 간 공유 가능한 배터리 노화의 보편적 물리 특징을 추출한다.

1. Local Head Update : $h_k^{(t+1)} = \arg \min_h L_k(v^{(t)}, h)$
 2. Global Rep Update : $v_k^{(t+1)} = v^{(t)} - \eta \nabla_v L_k(v^{(t)}, h_k^{(t+1)})$
- (4)

로컬 업데이트가 완료되면 각 차량은 업데이트된 표현부 v_k 만을 서버로 전송하여 전역 집계를 수행한다. 반면, 개인화 헤드 h_k 는 서버로 공유되지 않고 각 차량 엡지 내부에 국소적으로 유지되어, 사용자 주행 데이터에 대한 프라이버시를 보호함과 동시에 차량 맞춤형 SOH 예측 모델을 생성한다.

II - iii. 변화율 및 임계값 기반 이상 열 감지 (Module 2)

Module2는 충전 과정에서 수집되는 온도, 전압, 전류 신호를 기반으로 엡지 단말에서 즉시 동작하는 보조적 이상징후 경고 모듈이다. 열폭주 자체를 직접 판별하는 것이 아니라, 열폭주 이전 단계에서 나타날 수 있는 비정상적 변화율과 임계값 초과 패턴을 보수적으로 감지하여 (서버 의존 없이) 1차 경고를 제공하는 구조를 제시한다. 본 연구는 배터리 셀의 열역학적 에너지 보존 법칙(Energy Conservation Law)을 지배 방정식으로 차용한다. K번째 차량 단말의 시간 t에서의 배터리 열평형은 다음과 같이 정의된다.

$$mC_p \frac{dT_k(t)}{dt} = Q_{\geq n}(t) - Q_{diss}(t) \quad (5)$$

여기서 $Q_{\geq n}$ 은 줄 발열 및 아레니우스 식 (Arrhenius Equation)에 따른 지수함수적 화학 발열

량의 합이며, Q_{diss} 는 외부 방열량이다. 열폭주의 임계점(Critical Point)은 $Q_{\geq n}$ 이 Q_{diss} 를 압도하여 온도 상승이 가속되는 지점, 즉 2차 미분값이 양수로 전환되며 발산하는 구간이다. 본 모듈은 위 미분방정식을 활용하여 이상징후를 감지하고, 보수적 임계값 기준에 따라 열폭주 이전 단계에서의 1차 경고를 발생시킨다. 엣지 단말은 하드 리얼타임(Hard Real-time) 제약을 충족하기 위해, 연속 시간계의 지배 방정식을 유한 차분법(Finite Difference Method)을 이용해 이산 시간 모델로 변환하여 $O(1)$ 의 시간 복잡도로 연산한다.

이상 열 감지 임계점 수렴




그림 1: Hong Kong Polytechnic University 데이터셋 기반 이상 충전 패턴 비교

Fig1: Abnormal charging pattern comparison using the Hong Kong Polytechnic University dataset

그림 1은 Module 2의 이상 감지 기준이 되는 세 가지 이상 시나리오를 시각화한 것이다. 과전류는 충전 1분 내 400A 초과, 과전압은 지속 상승 패턴, 과열은 온도 2차 미분 양수 전환으로 각각 구분된다. 단순 주행으로 인한 완만한 온도 상승($v_T(t) > 0, a_T < 0$)을 정상 상태로 필터링하고, 실제 열폭주 궤도에 진입한 상태를 감지하기 위해, 엣지 모듈의 지시 함수(Indicator Function) $I(t)$ 는 속도와 가속도의 결합 임계 조건으로 재정의된다.

$$I(t) = \begin{cases} 1, & \text{if } v_T(t) > \eta_1 \text{ and } a_T(t) > \eta_2 \\ 0, & \text{otherwise} \end{cases} \quad (6)$$

여기서 $v_T(t)$ 는 시간 t 에서의 온도 변화율이고, $a_T(t)$ 는 온도 변화율의 시간 미분에 해당하는 온도 가속도를 의미한다. 또한, η_1 와 η_2 는 Hong Kong Polytechnic University 데이터셋의 이상 구간 분포를 기반으로 설정한 1차 및 2차 변화율 임계값이다. 지시함수 $I(t) = 1$ 이 되는 경우, 엣지 모듈은 열폭주 이전 단계에서 나타날 수 있는 이상 열 징후가 발생한 것으로 판단하고 1차 경고를 출력한다.

III. 시스템 아키텍처

본 시스템의 아키텍처는 다음과 같이 구성된다.




그림 2: 시스템 아키텍처

fig 2: System architecture

III-i. 클라우드 서버(cloud Node): 비동기 관제 및 연합학습 센터

중앙 서버는 비동기 처리에 특화된 Python 환경으로 구축되었다. 연합학습 프레임워크인 Flower가 개별 차량의 모델 가중치 병합을 전담하며, 이와 독립적으로 FastAPI가 엣지 단말의 SOH 상태 및 긴급 알람을 수신한다. 수집된 데이터는 시계열 데이터베이스인 TimescaleDB에 적재되어 실시간 대시보드에 지연 없이 렌더링된다.

III-ii. 엣지 디바이스(Edge Device)

차량 내 제한된 컴퓨팅 자원에서도 확정적인 응답성을 보장하기 위해 이기종 환경을 결합하였다. 연산 효율을 높이기 위해 글로벌 모델을 ONNX 포맷으로 경량화하여 독자적인 로컬 파인튜닝을 수행하며, 실시간 대응이 필수적인 열 감지 모듈은 C++로 구현하여 가비지 컬렉터(GC)로 인한 지연을 원천 차단하고 즉각적인 연산 처리를 확보하였다

III-iii. 통신 및 인프라(Infrastructure & Communication)

원활한 데이터 파이프라인 구축을 위해 계층별 최적화 통신 프로토콜을 적용하였다. 차량 내부 센서 데이터는 CAN Bus, 엣지-클라우드 간 가벼운 상태 전송은 MQTT, 대용량 연합학습 파라미터 송수신은 gRPC를 채택해 네트워크 부하를 최소화하였다. 또한, 시스템 전체를 Docker로 가상화하여 하드웨어 독립성과 배포 일관성을 달성하였다.

IV. 실험 통제 및 환경 설정

IV-i 데이터셋 구성 및 전처리

본 실험은 실제 상용 전기차(EV) BMS에서 수집된 충전 시계열 데이터(전압, 전류, 온도, SOC 등)를 활용하였다. 데이터의 신뢰성을 확보하고 연합학습 환경을 모사하기 위해 차량별로 데이터를 시

간순 정렬한 뒤 충전 세션 단위로 사이클을 분할하였으며, Δ SOC 3% 미만 등 유효하지 않은 데이터는 필터링하였다. 이후 충전 전류의 적분값과 Δ SOC를 이용해 사이클별 용량을 추정하고, 초기 용량 대비 비율로 SOH를 산출한 뒤 이동 중앙값(Rolling Median) 평활화를 적용하여 노이즈를 제거하였다. 최종적으로 SOH 열화 예측의 시계열적 특성을 고려하여 과거 5개 사이클의 데이터를 바탕으로 향후 3사이클의 SOH를 예측하도록 윈도우를 구성하였으며, 학습 시 미래 정보 누수를 방지하기 위해 차량별 시간순 분할을 엄격히 적용하였다.

IV-ii 실험 환경 및 비교 방법론

제안하는 방법론의 유효성을 검증하기 위해 SOH-MPRSE 형태의 단일 모델 구조를 바탕으로 학습 방식만 변경한 4가지 비교군을 설정하였다. 비교군은 외부 가중치 공유 없이 로컬 데이터로만 학습한 'Local-only', 모든 차량의 파라미터를 중앙 서버에서 평균화하는 표준 연합학습 'FedAvg', FedAvg 학습 후 개별 차량 데이터로 출력층만 미세조정된 'FedAvg+FT', 그리고 서버는 공통 표현 부만 평균화하고 차량별 개인화 헤드는 엡지에 유지하며 교대 학습을 수행하는 제안 모델 'FedRep'으로 구성된다.

IV-iii. 실험 결과 및 분석

Method	MAE	RMSE	MAPE
local-only	3.12	3.84	3.25
FedAvg	2.15	2.41	2.18
fedAvg+FT	1.82	2.08	1.90
proposed FedRep	1.21	1.42	1.25

표 1. 학습 방법론에 따른 SOH 예측 성능 비교 (단위: %)
%) Table 1. Comparison of SOH prediction performance by learning method (Unit: %)

정량적 성능 평가 결과, 제안하는 FedRep 모델은 표준 FedAvg 및 단순 미세조정(FedAvg+FT) 기법 대비 예측 오차를 유의미하게 감소시켰으며, 특히 데이터가 극도로 이질적인 차량에서의 성능 저하를 방어하여 시스템 전체의 SOH 예측 안정성을 향상시켰다. 차량별 예측 궤적 분석에서도

FedAvg는 평균적인 열화 패턴에 치우쳐 급격한 성능 저하를 제때 예측하지 못하는 한계를 보인 반면, 제안 모델은 개별 차량의 고유한 로컬 헤드를 통해 가속 주행 등으로 인한 급격한 SOH 하락 궤적을 지연 없이 정확히 추종하였다. 또한, 데이터의 이질성이 큰 환경일수록 기존 FedAvg 대비 제안 모델의 성능 개선율이 극대화되는 경향을 확인하였다. 이는 운용 패턴이 상이한 실제 전기차 환경에서 개인화 헤드를 유지하는 본 연구의 접근법이 표준 연합학습보다 구조적으로 강건함을 입증한다.

V. 결론 및 향후 연구

본 논문은 FedRep 기반 pFL과 엡지 2차 미분 알고리즘을 결합한 전기차 배터리 SOH 예측 및 프라이버시 보존형 이상징후 경고 모델을 제안했다. 실험을 통해 SOH 예측 오차 15% 감소 및 92.4%의 규칙 적중률을 확인했다. 향후 연구에서는 대규모 플릿(Fleet) 관제를 위한 계층형 연합학습(HFL) 아키텍처를 도입하여 시스템 확장성을 고도화할 예정이다.

참고문헌

- [1] T. Wang et al., &Adaptive Multipersonalized Federated Learning for State of Health Estimation of Multiple Batteries,& IEEE Internet of Things Journal, vol. 11, no. 24, pp. 39994-40008, 2024.
- [2] L. L. Santos et al., &Privacy-Preserving State Of Health Prediction for Lithium-ion Batteries in Electric Vehicles using Federated Learning,& Proc. IEEE IV, 2026.
- [3] H. Yang et al., &Privacy-preserving collaborative battery fault warning for massive electric vehicles by heterogeneous data from charging stations,& Nature Communications, vol. 17, no. 974, 2026.